

Large Language Models for Clinical Diagnosis and Treatment Recommendation

Bachelor Semester Project S2 (Academic Year 2025/26)

University of Luxembourg

Can Yildiz

can.yildiz.001@student.uni.lu

Nina Vojtassak

nina.vojtassak.001@student.uni.lu

Tuna Karakus

tuna.karakus.001@student.uni.lu

Résumé. Les systèmes d'aide à la décision clinique fondés sur les grands modèles de langage représentent une frontière prometteuse en intelligence artificielle médicale. Ce projet, intitulé Project Omega, présente une évaluation comparative systématique de deux modèles de langage à poids ouverts, LLaMA-3.3-70B de Meta et Gemma-4-31B de Google, sur la tâche d'hypothèse de diagnostic clinique et de recommandation de traitement à partir de dossiers médicaux électroniques réels.

À partir d'une cohorte reproductible de 2 000 admissions de patients issue de la base de données clinique MIMIC-IV, nous construisons des invites richement structurées incluant les données démographiques des patients, l'ensemble des diagnostics codés ICD, les mesures de laboratoire, les signes vitaux en unité de soins intensifs, les données anthropométriques OMR, les procédures et les résultats de cultures microbiologiques. Chaque modèle est chargé de générer des hypothèses de diagnostic différentiel, des recommandations de traitement, des alertes de sécurité et une évaluation de confiance clinique dans un format de sortie structuré.

L'évaluation est conduite selon six dimensions complémentaires : la verbosité des sorties, le chevauchement médicamenteux entre les recommandations des modèles et les prescriptions réelles, la similarité lexicale BLEU et ROUGE-1/2/L, et quatre axes de qualité clinique évalués par un évaluateur autonome basé sur un grand modèle de langage. L'évaluateur autonome, GPT-OSS 120B, attribue à chaque sortie une note de précision clinique, d'exhaustivité, de sécurité et d'utilité pratique sur une échelle de 1 à 25 par dimension. L'évaluateur désigne également un vainqueur pour chaque évaluation patient.

Les résultats révèlent que Gemma-4-31B remporte 1 959 des 2 000 évaluations en tête-à-tête (97,9%), surpassant substantiellement LLaMA-3.3-70B sur toutes les dimensions de qualité clinique. Simultanément, LLaMA obtient de meilleurs scores BLEU (0,052 contre 0,018) et ROUGE-1 (0,220 contre 0,121). Cette contradiction apparente s'explique par un effet de brèveté : les sorties plus courtes et centrées sur le diagnostic de LLaMA produisent un chevauchement lexical plus important avec les chaînes de référence ICD concises, tandis que les réponses complètes de Gemma sont pénalisées malgré une qualité clinique supérieure. Cette constatation met en évidence une limitation fondamentale des métriques n-gramme pour l'évaluation de la génération de texte clinique en format libre.

Une expérience de sensibilité à la température sur 1 000 patients avec trois réglages ($T \in \{0,1, 0,5, 1,0\}$) montre que la qualité des sorties de Gemma est largement robuste à cet hyperparamètre dans la plage testée. L'analyse d'explicabilité basée sur LIME confirme que les deux modèles s'ancrent principalement sur les sections Diagnostics et Résultats de laboratoire de l'invite, la section Diagnostics étant le prédicteur le plus fort du vocabulaire de sortie pour LLaMA, et un schéma d'influence plus distribué étant observé pour Gemma.

Le projet contribue un pipeline d'évaluation reproductible, un cadre d'évaluation multidimensionnel combinant des métriques lexicales avec une évaluation de la qualité clinique basée sur les grands modèles de langage, ainsi que des preuves empiriques motivant l'adoption d'évaluateurs autonomes comme signal de qualité principal pour les tâches de génération de texte clinique.